Оптимизация закупок и хранения запасных процессоров с использованием нейросетевого многомерного интегрирования

Abstract

Рассматривается задача выбора периода закупки, размера страхового запаса и объёма партии запасных процессоров для крупного суперкомпьютерного центра. Неопределённость количества отказов и качества поступающих процессоров задаётся совместным распределением шести случайных величин. Для сравнения большого числа политик снабжения необходимо многократно вычислять интеграл одной и той же гладкой шестимерной функции по различным многогранным подобластям. Такая структура соответствует методу Neural Network Integration (NNI), предложенному в работе [1]: подынтегральная функция аппроксимируется неглубокой нейронной сетью один раз, после чего её интегралы по различным областям вычисляются ускоренно.

1 Мотивация

В крупном вычислительном центре даже невысокая вероятность отказа одного аппаратного компонента приводит к регулярным отказам на уровне всего парка оборудования. Практические исследования показывают, что неисправности процессоров, памяти, накопителей и других компонентов существенно влияют на доступность вычислительных систем [7, 8, 9].

Недостаток запасных процессоров вызывает простой вычислительных узлов и необходимость срочной закупки. Избыточный запас, напротив, приводит к затратам на хранение и риску морального устаревания. Задачи такого типа относятся к управлению запасами ремонтируемых и дорогостоящих компонентов. Классические модели METRIC и их современные обобщения рассматриваются в работах [2, 3, 4]; обзор моделей запасов запасных частей приведён в [5, 6].

2 Политика управления запасом

Суперкомпьютерный центр эксплуатирует

$$N = 20\,000$$

однотипных процессоров. Политика снабжения характеризуется тройкой

$$\pi = (T, s, Q),$$

где T — продолжительность периода между плановыми решениями о пополнении запаса, s — страховой запас, а Q — размер закупаемой партии.

Допустимые значения параметров имеют вид

$$T \in \{7, 14, 21, 28\}, \qquad s \in \{50, 60, \ldots, 300\}, \qquad Q \in \{100, 120, \ldots, 600\}. \tag{1}$$

Полный перебор множества (1) содержит

$$4 \cdot 26 \cdot 26 = 2704$$

различные политики.

3 Случайная модель отказов

Пусть

$$\boldsymbol{\xi} = (X_0, X_1, X_2, X_3, X_4, U)$$

— шестимерный случайный вектор. Здесь X_0 обозначает количество процессоров, отказавших за время поставки, X_i, $i = 1, \ldots, 4$, — количество отказов в i-м последовательном семидневном блоке периода контроля, а U — долю процессоров из новой партии, не прошедших входной контроль.

Для численного моделирования количества отказов рассматриваются как непрерывные величины. Область возможных значений задаётся прямоугольным параллелепипедом

$$D = [0, 100]^5 \times [0, 0.08] \subset \mathbb{R}^6. \tag{2}$$

Введём ненормированную совместную плотность

$$g(\boldsymbol{\xi}) = \exp\left[-\sum_{i=0}^{4} \frac{(x_i - \mu_i)^2}{2\sigma_i^2} - \frac{(u - 0.02)^2}{2(0.015)^2}\right] \times \left[1 + 0.15\cos\bigl(0.04(x_1 + x_2 - 2x_0)\bigr)\right], \tag{3}$$

где

$$\boldsymbol{\mu} = (30, 42, 45, 48, 52), \qquad \boldsymbol{\sigma} = (12, 15, 16, 18, 20).$$

Косинусный множитель моделирует статистическую зависимость между отказами в разные интервалы, возникающую вследствие общих режимов нагрузки и температуры. При этом

$$0.85 \le 1 + 0.15\cos\bigl(0.04(x_1 + x_2 - 2x_0)\bigr) \le 1.15,$$

поэтому функция (3) положительна на всей области D.

Для произвольной измеримой области $\Omega \subseteq D$ определим оператор

$$I(\Omega) = \int_{\Omega} g(\boldsymbol{\xi})\, \mathrm{d}\boldsymbol{\xi}. \tag{4}$$

Нормированная плотность случайного вектора равна

$$f(\boldsymbol{\xi}) = \frac{g(\boldsymbol{\xi})}{I(D)},$$

а вероятность попадания в область Ω вычисляется по формуле

$$\mathbb{P}\{\boldsymbol{\xi} \in \Omega\} = \frac{I(\Omega)}{I(D)}. \tag{5}$$

Таким образом, нормировка и все вероятностные характеристики требуют интегрирования одной и той же функции $g(\boldsymbol{\xi})$. Меняются только области интегрирования.

4 Потребность в запасных процессорах

Положим

$$T_j = 7j, \qquad j \in \{1, 2, 3, 4\}.$$

Суммарное число отказов в соответствующем периоде защиты запаса, включающем период контроля и время поставки, задаётся функцией

$$R_j(\boldsymbol{\xi}) = X_0 + \sum_{i=1}^{j} X_i. \tag{6}$$

Количество исправных процессоров, фактически поступивших в партии, равно

$$A_Q(U) = Q(1 - U). \tag{7}$$

Для фиксированных j и Q функции (6) и (7) являются аффинными по компонентам $\boldsymbol{\xi}$.

5 Области интегрирования

Для каждой политики (T_j, s, Q) определяются следующие подобласти области D.

5.1 Отсутствие дефицита

Запаса достаточно до поступления партии, если

$$R_j(\boldsymbol{\xi}) \le s.$$

Соответствующая область и её вероятность равны

$$\Omega_0(j, s) = \left\{ \boldsymbol{\xi} \in D : x_0 + \sum_{i=1}^{j} x_i \le s \right\}, \tag{8}$$

$$P_0(j, s) = \frac{I(\Omega_0(j, s))}{I(D)}. \tag{9}$$

5.2 Временный дефицит

Временный дефицит возникает, если страхового запаса недостаточно, но поступившая партия полностью покрывает потребность:

$$\Omega_1(j, s, Q) = \left\{ \boldsymbol{\xi} \in D : s < x_0 + \sum_{i=1}^{j} x_i \le s + Q(1 - u) \right\}, \tag{10}$$

$$P_1(j, s, Q) = \frac{I(\Omega_1(j, s, Q))}{I(D)}. \tag{11}$$

5.3 Критический дефицит

Если суммарная потребность превышает страховой запас и количество исправных процессоров в новой партии, возникает критический дефицит:

$$\Omega_2(j, s, Q) = \left\{ \boldsymbol{\xi} \in D : x_0 + \sum_{i=1}^{j} x_i > s + Q(1 - u) \right\}, \tag{12}$$

$$P_2(j, s, Q) = \frac{I(\Omega_2(j, s, Q))}{I(D)}. \tag{13}$$

Области Ω_0, Ω_1 и Ω_2 образуют разбиение D с точностью до границ нулевой меры. Поэтому

$$P_0(j,s) + P_1(j,s,Q) + P_2(j,s,Q) = 1. \tag{14}$$

5.4 Избыточный запас

Пусть $L = 250$ — максимально допустимый остаток процессоров после поступления партии. Тогда область образования избыточного запаса имеет вид

$$\Omega_3(j,s,Q) = \left\{ \boldsymbol{\xi} \in D : s + Q(1-u) - x_0 - \sum_{i=1}^{j} x_i > L \right\}, \tag{15}$$

$$P_3(j,s,Q) = \frac{I(\Omega_3(j,s,Q))}{I(D)}. \tag{16}$$

Все неравенства (8), (10), (12) и (15) линейны по переменным $x_0, \ldots, x_4, u$. Следовательно, области Ω_k являются пересечениями прямоугольника D с обобщёнными шестимерными многогранниками. Это существенно для применения метода NNI [1].

6 Экономический критерий

Введём параметры затрат:

Параметр	Значение	Содержание
K	40 000 руб.	оформление планового заказа;
c	180 000 руб.	закупка одного процессора;
h	120 руб./сутки	хранение одного процессора;
c_{tmp}	5 000 000 руб.	потери при временном дефиците;
c_{crit}	50 000 000 руб.	потери при критическом дефиците;
c_{exc}	3 000 000 руб.	потери при избыточном запасе.

Штрафы c_{tmp}, c_{crit} и c_{exc} интерпретируются как средние потери за цикл при наступлении соответствующего события. Тогда ожидаемые годовые затраты равны

$$J(T_j,s,Q) = \frac{365}{T_j}\big[K + cQ + hT_j s + c_{\text{tmp}}P_1(j,s,Q) + c_{\text{crit}}P_2(j,s,Q) + c_{\text{exc}}P_3(j,s,Q)\big]. \tag{17}$$

Требуется найти оптимальную политику

$$(T^*, s^*, Q^*) = \arg\min_{T_j,s,Q} J(T_j,s,Q) \tag{18}$$

при ограничении надёжности

$$P_2(j,s,Q) \le 0.01. \tag{19}$$

7 Применение метода NNI

Метод NNI [1] предполагает аппроксимацию функции $g : \mathbb{R}^6 \to \mathbb{R}$ неглубокой нейронной сетью с одним скрытым слоем:

$$\widehat{g}(\boldsymbol{\xi}) = b^{(2)} + \sum_{r=1}^{m} w_r^{(2)} \sigma\left(b_r^{(1)} + \sum_{i=0}^{5} w_{ri}^{(1)} \xi_i \right), \tag{20}$$

где

$$\sigma(v) = \frac{1}{1 + e^{-v}}$$

— логистическая функция активации, а m — число нейронов скрытого слоя.

Сеть (20) обучается на значениях одной функции $g(\boldsymbol{\xi})$ в области D. После обучения одна и та же сеть используется для приближённого вычисления

$$I(D), \qquad I\big(\Omega_0(j,s)\big), \qquad I\big(\Omega_k(j,s,Q)\big), \quad k = 1,2,3,$$

для всех допустимых значений j, s, Q.

Отдельное вычисление $I(\Omega_1)$ можно исключить, используя (14). Кроме того, P_0 не зависит от Q. Тем не менее для полного сравнения политик требуется вычислить не менее

$$104 + 2 \cdot 2704 = 5512$$

различных интегралов: 104 интеграла для P_0 и по 2704 интеграла для вероятностей критического дефицита и избыточного запаса. Поэтому затраты на однократное обучение сети могут компенсироваться быстрым вычислением нескольких тысяч интегралов по различным областям.

Для контрольного сравнения могут использоваться методы Монте-Карло, квази-Монте-Карло и адаптивные квадратурные алгоритмы [10, 11].

8 Задание

Необходимо выполнить следующие действия:

1. Сформировать обучающую и контрольную выборки точек из области D и вычислить значения функции (3).
2. Обучить сеть (20) и оценить ошибку аппроксимации функции g на контрольной выборке.
3. Методом NNI вычислить нормировочный интеграл $I(D)$.
4. Для всех допустимых политик вычислить вероятности P_0, P_1, P_2, P_3 и проверить равенство (14).
5. Исключить политики, не удовлетворяющие ограничению (19).
6. Для оставшихся политик вычислить целевую функцию (17) и найти решение (18).
7. Сравнить точность и время вычисления интегралов методами NNI, Монте-Карло и квази-Монте-Карло.
8. Исследовать зависимость точности NNI от числа нейронов m, размера обучающей выборки и способа формирования выборочных точек.
9. Провести анализ чувствительности оптимальной политики при увеличении интенсивности отказов, срока поставки и стоимости критического дефицита.

9 Ожидаемый результат

В результате должна быть найдена политика (T^*, s^*, Q^*), которая минимизирует ожидаемые годовые затраты при вероятности критического дефицита не более 1%. Одновременно требуется экспериментально проверить, обеспечивает ли предварительное обучение нейронной сети выигрыш по времени при многократном интегрировании одной функции по различным многогранным областям.

References

[1] S. Lloyd, R. A. Irani, and M. Ahmadi, "Using Neural Networks for Fast Numerical Integration and Optimization," *IEEE Access*, vol. 8, pp. 84519–84531, 2020. doi:10.1109/ACCESS.2020.2991966.

[2] C. C. Sherbrooke, "METRIC: A Multi-Echelon Technique for Recoverable Item Control," *Operations Research*, vol. 16, no. 1, pp. 122–141, 1968. doi:10.1287/opre.16.1.122.

[3] C. C. Sherbrooke, *Optimal Inventory Modeling of Systems: Multi-Echelon Techniques*, 2nd ed. New York: Springer, 2004. doi:10.1007/b109856.

[4] G.-J. van Houtum and B. Kranenburg, *Spare Parts Inventory Control under System Availability Constraints*. New York: Springer, 2015. doi:10.1007/978-1-4899-7609-3.

[5] W. J. Kennedy, J. W. Patterson, and L. D. Fredendall, "An Overview of Recent Literature on Spare Parts Inventories," *International Journal of Production Economics*, vol. 76, no. 2, pp. 201–215, 2002. doi:10.1016/S0925-5273(01)00174-8.

[6] R. J. I. Basten and G.-J. van Houtum, "OR in Spare Parts Management: A Review," *European Journal of Operational Research*, vol. 266, no. 2, pp. 395–414, 2018. doi:10.1016/j.ejor.2017.07.058.

[7] B. Schroeder and G. A. Gibson, "Disk Failures in the Real World: What Does an MTTF of 1,000,000 Hours Mean to You?" in *Proc. 5th USENIX Conf. File and Storage Technologies (FAST '07)*, San Jose, CA, 2007. https://www.usenix.org/conference/fast-07/disk-failures-real-world-what-does-mttf-1000000-hours-mean-you.

[8] H. S. Gunawi et al., "Fail-Slow at Scale: Evidence of Hardware Performance Faults in Large Production Systems," in *Proc. 16th USENIX Conf. File and Storage Technologies (FAST '18)*, Oakland, CA, 2018, pp. 1–14. https://www.usenix.org/conference/fast18/presentation/gunawi.

[9] P. H. Hochschild et al., "Cores That Don't Count," in *Proc. 18th Workshop on Hot Topics in Operating Systems (HotOS '21)*, 2021, pp. 9–16. doi:10.1145/3458336.3465297.

[10] H. Niederreiter, *Random Number Generation and Quasi-Monte Carlo Methods*. Philadelphia, PA: SIAM, 1992. doi:10.1137/1.9781611970081.

[11] A. C. Genz and A. A. Malik, "Remarks on Algorithm 006: An Adaptive Algorithm for Numerical Integration over an N-Dimensional Rectangular Region," *Journal of Computational and Applied Mathematics*, vol. 6, no. 4, pp. 295–302, 1980.